

Neural ODEs sobre Datos Biológicos

Análisis Numérico — Universidad Nacional de Colombia

Profesor: Carlos Manuel Orrego Franco

Integrantes: Juan Jose Valencia, Juan Diego Buritica

23 de Mayo de 2026

Dataset: COVID-19 JHU (nuevos casos diarios)

1. Descripción del dataset

- **Dataset:** COVID-19 JHU (nuevos casos diarios)
- **Trayectorias:** 178
- **Pasos de tiempo:** 400
- **Dimensiones:** 1
- **Variables:** Nuevos casos (norm.)
- **Rango:** [-1.098, 7.928]

Al observar las trayectorias de exploración se pudo ver que el comportamiento de los nuevos casos es muy irregular y no lineal, se puede observar picos abruptos y seguidos de cierta estabilidad, lo cual genera una falta de “suavidad” en la curvas además de una cantidad de olas agresivas.

2. Hiperparámetros elegidos y justificación

- `dim_latente`: 8
- `n_pasos_ode`: 10
- `learning_rate`: 0.001
- `n_epochs`: 25
- `batch_size`: 32
- `dim_oculto_f`: 48
- `dim_oculto_enc`: 32
- `dim_oculto_dec`: 48

Primero, elegimos 8 dimensiones latentes porque es una cantidad tan alta para evitar que el entrenamiento se trunque y no es una cantidad tan baja para que la red tenga la capacidad de aprender.

Elegimos 10 pasos de integración porque no es una cantidad tan alta para evitar altos costos de computación y no es una cantidad tan baja para que el error no aumente gradualmente lo que implicaría un entrenamiento pobre.

Elegimos una tasa de aprendizaje de 0.001 porque no es un valor muy grande para evitar que el entrenamiento no se vuelva inestable lo que provocaría que no converja un mínimo y porque no es un valor muy pequeño lo que provocaría que el entrenamiento se vea truncado con lo cual tendría el riesgo convergería a un mínimo local.

Elegimos 25 épocas porque es una cantidad que consideramos adecuada para que el modelo tenga tiempo de aprender los datos o no sea excesivamente grande lo cual implicaría que el modelo deje de aprender y solo memorice los datos de entrenamiento.

3. Tabla de resultados RMSE

Modelo	30 % rec	30 % ext	60 % rec	60 % ext	100 % rec	100 % ext	Params	Tiempo
Método Clásico	0.0000	0.1142	0.0000	0.0866	0.0000	nan	4	0.0s
Neural ODE	0.5002	0.5014	0.4982	0.5052	0.5010	nan	3,721	2051.3s
Latent ODE	0.5833	0.5829	0.5810	0.5862	0.5831	nan	7,593	2666.6s

Cuadro 1: Resultados RMSE para reconstrucción (rec) y extrapolación (ext).

4. Figuras




Figura 1: Exploración del dataset




Figura 2: Comparación de modelos (60 % obs.)




Figura 3: Curvas de aprendizaje

5. Respuestas a las preguntas de análisis

P1: ¿Con qué porcentaje de observaciones empieza a ganar la Neural ODE?

Según los datos obtenidos podemos concluir que en ningún porcentaje de observación la Neural EDO le “gana” al modelo clásico, los datos obtenidos son los siguientes:

- Modelo clásico: 0.000/0.114 0.000/0.087 0.000/nan
- Neural ODE: 0.500/0.501 0.498/0.505 0.501/nan

Estos resultados corresponden a un porcentaje de 30 %, 60 % y 100 % respectivamente. Esto puede deberse al hecho de que la Neural EDO asume que los datos siguen una trayectoria continua suave pero estos datos contienen un ruido alto dado que están expuestos a muchos errores humanos. Por otro lado, esto lo podemos relacionar con el notebook 7, pues en este estudiamos el error de reconstrucción y extrapolación.

P2: ¿Por qué el encoder RNN corre en orden inverso al tiempo?

Corre en orden inverso al tiempo para calcular el estado inicial z_0 en el tiempo t_0 , esto porque el decodificador está diseñado para empezar desde el tiempo inicial que contenga información sobre los datos y esto se logra primero obteniendo el estado inicial usando una trayectoria inversa.

P3: ¿Hubo algún resultado sorpresivo? ¿Por qué?

Sí, un resultado sorpresivo fue el hecho de ver que la Neural EDO no siempre supera al modelo clásico; pues en sistemas donde los datos contengan mucho ruido, es decir, que su gráfica represente picos abruptos, pues esto castiga mucho el error de reconstrucción y extrapolación de la Neural EDO. Por otro lado, esto se relaciona con el Notebook 1 y Notebook 6 pues en este se estudió las limitaciones de los métodos continuos como el Neural EDO, también se relaciona con el notebook 7 donde se vio una posible solución probabilística para el ruido de los datos.

P4: ¿En qué tipo de problema NO recomendarían una Neural ODE?

En casos donde los datos presenten un ruido alto lo que ocasiona que la trayectoria continua pierda precisión a la hora de reconstruir y extrapolar, en nuestro caso esto se ve reflejado en las gráficas de exploración pues estas representan una serie de picos abruptos y una cantidad de “olas” grandes, además de serie de sucesos que afectan las observaciones, como por ejemplo que los casos registrados no presenten una distribución “suave”.

6. Conclusiones

Podemos concluir que:

- Para la aplicación del método de neural EDO se necesita un estudio previo de los datos y de sus gráficas de exploración, pues existen modelos para los cuales es mejor el método clásico.
- También se pudo ver la importancia del ruido en los datos, pues esto afectó directamente la efectividad de los métodos propuestos.
- También podemos concluir que la relación costo vs efectividad no siempre se cumple de forma proporcional, es decir, un mayor costo computacional no garantiza un mejor modelo, esto también lo exploramos en el notebook 6 donde se vieron las limitaciones de estos modelos continuos.